M38 Prelabel Studio

Model Compression for Edge Pre-Labeling

Tạo nhãn gợi ý trên CPU
Con người kiểm sửa trước khi xuất

YOLOv8s COCO pretrained / ONNX Browser / OpenVINO INT8

Đội 030 Sakana
Lê Đức Mạnh, Phạm Hoàng Anh, Võ Trọng Nghĩa

Bài toán gán nhãn trên CPU

Nhãn gợi ý chỉ hữu ích khi người dùng có thể kiểm tra và sửa lỗi

Chi phí thao tác

Vẽ và chỉnh bounding boxes thủ công.
Prelabel sai tạo thêm công kiểm sửa.

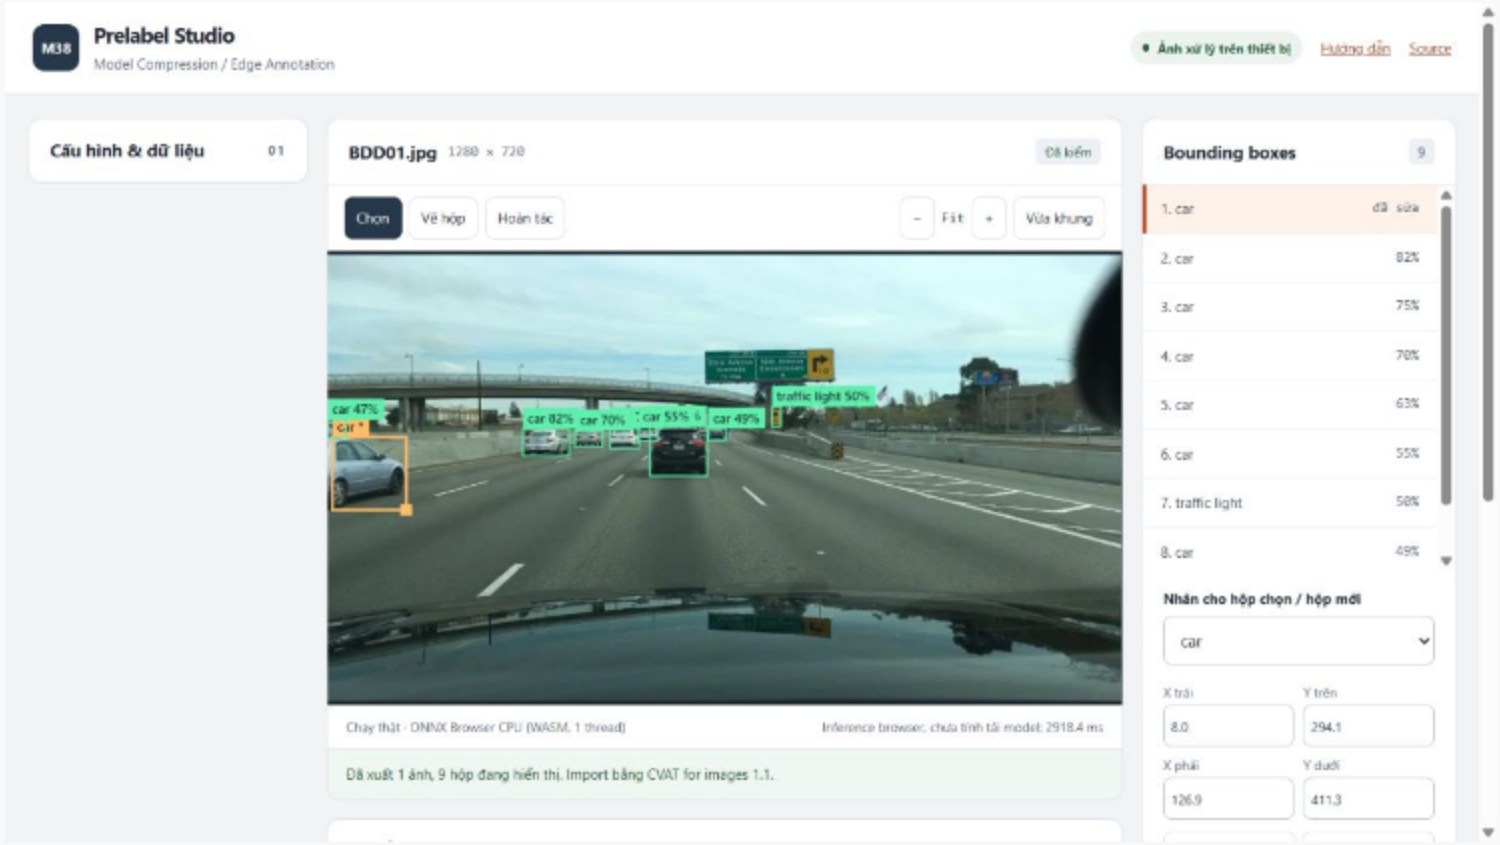
Ràng buộc triển khai

Chạy inference trên CPU.
Đo đánh đổi giữa latency, dung lượng và mức thay đổi prediction sau nén.

Mục tiêu: giảm công vẽ nhãn, giữ quyền quyết định cho annotator.
Mức tiết kiệm thời gian thực tế cần được đo bằng pilot.

Studio đang chạy được

Chạy ONNX thật trong browser và xuất CVAT for images 1.1 XML



Ảnh mẫu hoặc ảnh riêng

Zoom, vẽ, sửa, xóa hộp

Hoàn tác và kiểm nhãn

Xuất XML cho CVAT

Pipeline và tính đúng đắn

Cùng preprocessing và NMS để so sánh các runtime

01 Ảnh RGB và letterbox 640

Padding 114, chuẩn hóa /255, input NCHW

02 YOLOv8s trên các runtime CPU

PyTorch, ONNX Runtime, OpenVINO FP16 và INT8

03 NMS theo lớp và người kiểm sửa

Hash ảnh/model, kết quả đúng ảnh, xuất cùng trạng thái hiển thị

INT8 đạt mean latency 38,80 ms

Python CPU, 4 threads, 26 ảnh × 3 lượt, 3 warmup



3,96×

Tỷ số latency so với PyTorch
trong cùng phép đo

INT8: 11,24 MiB
ONNX: 42,79 MiB

Gồm preprocessing + NMS. Không tính đọc ảnh/nạp model. Chưa kiểm soát nhiệt/nguồn điện.
Dung lượng artifact khác định dạng không chứng minh mức giảm RAM. Browser đo riêng.

Độ đồng thuận sau chuyển đổi và nén

10 ảnh holdout, 97 hộp PyTorch tham chiếu, ghép cùng lớp tại IoU ≥ 0,5

Runtime	Hộp ghép / tham chiếu	Mean IoU
ONNX	97 / 97	1,0000
OpenVINO FP16	97 / 97	0,9997
OpenVINO INT8	94 / 97	0,8092

Đây là agreement với PyTorch. Chưa có mAP ground truth.

Calibration: 16 ảnh hash khác holdout. Chưa xác minh độc lập theo scene.